

Processo de *Data Warehousing*

Sistemas de Apoio à Decisão

Processo de *Data Warehousing*


- Sumário
 - Metodologias
 - *Corporate Warehouse*
 - *Dimensional Design*
 - Outras Metodologias e Arquiteturas
 - Arquitetura do *Data Warehouse*
 - Construção de um *Data Warehouse*
 - Atividades principais
 - Fases de construção de um *Data Warehouse*

Metodologias

- *Corporate Warehouse*
 - *Building the Data Warehouse*
B. Inmon, 1990
 - Arquitetura para coleção de dados de fontes **heterogéneas** numa **base de dados** com elevado nível de **detalhe** e dependente do **tempo**
 - Abordagem *top-down*
 - Dados estruturados
 - **Formulação** da metodologia *Corporate Information Factory* em 2002

Metodologias

- *Corporate Warehouse*
 - *Top-down*
 - Modelo **complexo** (DERs)
 - Nível da **organização**
 - **Integração** via modelo de dados da organização
 - **Data marts** caracterizados como **agregados**




Metodologias

- *Dimensional Design*
 - *The Data Warehouse Toolkit*
R. Kimball, 1996
 - Arquitetura para diferentes bases de dados, *data marts*, organizadas em função dos **processos de negócio** da organização
 - Abordagem *bottom-up*
 - Dados estruturados
 - Formulação da metodologia *Business Dimensional Lifecycle* em 2002

Metodologias

- *Dimensional Design*
 - *Bottom-up*
 - Modelo dimensional
 - Processo de negócio
 - Integração através de dimensões conformes
 - *Data marts* caracterizados ao nível atómico
 - Metodologia **adotada** na unidade curricular




Metodologias

- Outras Metodologias e Arquiteturas
 - *Data Vault*
 - Daniel Linstedt, Lockheed Martin, 2000
 - Abordagem híbrida baseada na normalização e na modelação dimensional
 - Conceitos nucleares: *hub*, *link* e *satélite*
 - Guarda uma “única versão dos factos” em oposição a uma “única versão da verdade” no *Data Warehouse*
 - Permite o desenvolvimento ágil, resiliência à mudança e escalabilidade

Metodologias

- Outras Metodologias e Arquiteturas
 - *Data Vault*




Metodologias

- Outras Metodologias e Arquiteturas
 - *Data Lake*
 - James Dixon, Pentaho, 2011
 - Repositório para armazenar **grandes quantidades** de dados de diferentes fontes no seu formato **natural/bruto**
 - Natureza *ad hoc* dos dados, por oposição aos dados limpos e processados num DW
 - Dados **estruturados, semiestruturados e não estruturados**
 - Utilizado por empresas *Big Data*

Metodologias

- Outras Metodologias e Arquiteturas
 - *Data Lake*




Metodologias

- Outras Metodologias e Arquiteturas
 - *Data Lakehouse*
 - Databricks Company, 2020
 - Infraestrutura de armazenamento em que tudo é feito nos dados fonte em tempo real
 - Dados estruturados, semiestruturados e não estruturados
 - Tenta combinar o melhor dos *data lakes* e dos *data warehouses*
 - Diferentes utilizações
 - ETL, *Business Intelligence*, *Data Science*, ML


Metodologias

- Outras Metodologias e Arquiteturas
 - *Data Lakehouse*



Metodologias

• Outras Metodologias e Arquiteturas




Metodologias

- Outras Metodologias e Arquiteturas
 - *Data Fabric*
 - Conceito: Forrester Company, 2013
 - **Arquitetura de dados** moderna que cria uma camada para unificar e integrar dados de diferentes plataformas e ambientes
 - Visão **holística** e conectada de todos os dados da organização
 - Fonte única e fiável da realidade
 - Diferentes utilizações
 - *Business Intelligence, Analytics, Data Science*

Metodologias


- Outras Metodologias e Arquiteturas
 - *Data Fabric*



Processo de *Data Warehousing*

- Sumário
 - Metodologias
 - *Corporate Warehouse*
 - *Dimensional Design*
 - Outras Metodologias e Arquiteturas
 - **Arquitetura do *Data Warehouse***
 - Construção de um *Data Warehouse*
 - Atividades principais
 - Fases de construção de um *Data Warehouse*


Arquitetura do DW



Sistemas Fonte

- Sistemas que permitem realizar e registar as **operações críticas** do negócio
- Características:
 - **Disponibilidade**
 - As consultas envolvem **poucos registos**
 - Guardam **poucos dados** históricos
 - **Consultas** que envolvam **muitos registos** demoram **muito tempo** e podem afetar o funcionamento normal do sistema
 - Geralmente, existem **vários sistemas** e de diversos tipos, podendo existir **inconsistências** entre eles

Arquitetura do DW



Área de Tratamento de Dados

- *Data Staging Area (DSA)*
 - Área de armazenamento e conjunto de processos que permitem **extrair, transformar** e **carregar** os dados dos sistemas fonte para serem utilizados no *data warehouse*

Área de Tratamento de Dados

- Processo de Extração
 - Consiste no **processo de compreender, selecionar e copiar** os dados fonte para a área de tratamento de dados
 - Exportação de dados (ficheiro)
 - Extração de dados (código específico ou ferramentas)
 - No **processo de extração** existem duas situações bem distintas
 - Primeira extração de dados
 - Extrações incrementais


Área de Tratamento de Dados

- Processo de Transformação
 - O processo de transformação envolve duas atividades principais
 - Verificação da **qualidade dos dados**
 - **Transformações** de dados
 - Existem várias formas de **transformar os dados** provenientes dos sistemas fonte
 - **Limpeza** dos dados
 - **Eliminação de campos inúteis**
 - **Combinação** de dados de fontes diferentes
 - Verificação exata de chaves ou “fuzzy matches”

Área de Tratamento de Dados

- Processo de Carregamento
 - Depois de transformados os **dados** são **carregados** para o *data warehouse*
 - São carregados muitos regtos de uma só vez (*bulk loading*), pois carregar um registo de cada vez seria demasiado lento
 - Depois de carregados os **dados** são **indexados**
 - Construção de **agregados** de modo a acelerar as pesquisas

Arquitetura do DW



Data Marts


- *Data Marts*
 - Um *data mart* é um **subconjunto lógico** de um *data warehouse*
 - Um *data mart* está normalmente relacionado com apenas um determinado **processo de negócio**
 - Um *data warehouse* não é mais do que a **união** dos seus *data marts*
 - As **dimensões** e os **factos** dos vários *data marts* devem ser **conformes**

Data Marts

- Metadados
 - Dados que **descrevem os dados** existentes no *data warehouse*
 - Devem descrever, entre outras coisas:
 - **Estrutura** (o quê, onde, como, quando)
 - **Formato** dos dados
 - **Relação** entre os dados do *Data Warehouse* e os dados **dos sistemas fonte** (o que inclui a descrição dos algoritmos de tratamento)
 - **Origem dos dados** do *data warehouse* e quem são **os seus donos**



Arquitetura do DW

Sistemas Fonte



Data Staging Area
Área de Tratamento
de Dados
ETL

Data Marts



Utilizadores Finais

- Aplicações cliente
 - Conjunto de **aplicações analíticas** que permitem aos utilizadores fazer consultas ao *data warehouse*, analisar e apresentar o resultado dessas consultas
 - Devem ser bastante **fáceis de utilizar** e permitir realizar pesquisas *ad hoc*
 - Devem apresentar a **informação** de um **modo fácil de entender** (*tabelas, gráficos, dashboards, reports, etc.*)

Utilizadores Finais

- Aplicações cliente: Exemplo

Marca	Valor rendido	Unidades vendidas
Cigala	780,00	263
Compal	1044,00	509
Delta	213,00	444
Galo	95,00	39

- Arrastar o atributo **Marca** e colocá-lo como primeira coluna
- Arrastar os atributos **Valor rendido** e **Unidades vendidas** da tabela de factos
- Definir a restrição '1T 2025' no atributo **Trimestre** da dimensão tempo


Utilizadores Finais

- Aplicações para análise de dados
 - Capacidade de **analisar os dados** fornecidos pelo *data warehouse*
 - Estas aplicações incluem:
 - Modelos com **capacidade de previsão**
 - **Modelos** que permitem **agrupar** e **classificar** comportamentos
 - Ferramentas de ***data mining***

Processo de *Data Warehousing*

- Sumário
 - Metodologias
 - *Corporate Warehouse*
 - *Dimensional Design*
 - Outras Metodologias e Arquiteturas
 - Arquitetura do *Data Warehouse*
 - **Construção de um *Data Warehouse***
 - Atividades principais
 - Fases de construção de um *Data Warehouse*

Construção do DW



Construção do DW

- Atividades principais
 - Tecnologia
 - Dados
 - Modelação dimensional
 - Desenho físico
 - Desenho e desenvolvimento da área de tratamento dos dados
 - Aplicações analíticas

Construção do DW

- Metodologia de Ralph Kimball
 - Fases ou etapas de construção
 1. Identificação de **objetivos** a atingir
 2. Definir **infraestrutura** para o projeto
 3. Identificar modelo de dados dos **sistemas fonte**
 4. Definir **modelo de dados** do *data warehouse*
 5. Definir **regras** para o **mapeamento** dos dados
 6. **Extrair, integrar, purificar** e **racionalizar** dados
 7. Exploração, **afinação de desempenho** e avaliação da eficácia do *data warehouse*

Fases de Construção

1. Identificação de objetivos

- É indispensável ter um entendimento profundo do **processo de negócio** que o *data warehouse* vai apoiar
 - Quais são os **objetivos** e **estratégia** da empresa?
 - Qual a **informação necessária** para atingir esses objetivos?
 - **Porque é** que a informação é necessária?
 - **Quem** vai usar essa informação?
 - **Como** é que a informação vai ser usada?

Fases de Construção

2. Infraestrutura para o projeto

- A construção de um *data warehouse* é uma **tarefa complexa** e requer conhecimento especializado em várias áreas
 - Definir **equipa**
 - Definir **ferramentas** e **sistemas**
 - Identificar as **fases do projeto**
 - Definir **métodos de trabalho**
 - Identificar **responsabilidades** para cada tarefa/fase

Fases de Construção

3. Modelo de dados dos sistemas fonte

- Questão: Quais os dados fonte necessários para o *data warehouse*?
 - Modelos de dados das BD operacionais estão desatualizados ou não existem
 - Necessárias ferramentas de *reverse engineering*
 - Alguns dados do *data warehouse* podem ter outras origens que não as BDs operacionais
 - No processo de identificação dos dados a extrair
 - Dados históricos (factos)
 - Dados de referência (dimensões)
 - Sínteses ou sumários (agregados)

Fases de Construção

4. Modelo de dados do *Data Warehouse*

- Compreender/desenvolver o modelo de negócio do *data warehouse*
 - Identificar **processos de negócio**
 - Identificar **dados disponíveis**
- Para cada processo de negócio
 - Identificar os **factos** (valores numéricos)
 - Escolher a **granularidade dos factos** (vai determinar a precisão com que poderá ser feita a análise dos dados)
 - Definir as **dimensões** de interesse

Fases de Construção

5. Mapeamento de dados

- Identificar os **dados a extrair**
- Identificar os **dados que faltam** (que não é possível extrair das BD operacionais)
- Definir regras e processos para **integrar**, **compatibilizar** e “**limpar**” os dados
- **Documentar** os passos para permitir que os dados históricos possam ser entendidos posteriormente

Fases de Construção

6. Extrair, integrar e purificar dados

- Usar ou construir as ferramentas que permitam implementar as regras para **mapeamento dos dados**
- **Rever** as regras e os processos de mapeamento sempre que são detetadas inconsistências
- **Documentar** todos os passos

Fases de Construção

7. Exploração, afinação e avaliação

- Definição/construção de **ferramentas de exploração** de dados
- Afinação do **desempenho**
 - Otimização de consultas
- **Administração** do *data warehouse*

Processo de *Data Warehousing*

- Referências
 - The Data Warehouse Lifecycle Toolkit, R. Kimball, John Wiley & Sons, 2008
 - Capítulo 1
 - The Data Warehouse Toolkit, R. Kimball, John Wiley & Sons, 2013 (3^a edição)
 - Capítulo 17
 - Building the Data Lakehouse; W. Inmon e R. Srivastava, Technics Publications, 2023