

Carregamento de Dados

Sistemas de Apoio à Decisão

Carregamento de Dados

- Sumário
 - Introdução
 - Processo de Carregamento
 - Técnicas SCD
 - Passos Típicos do Processo ETL


Introdução

- Processo ETL
 - Permite **migrar** dados dos **sistemas fonte** para o **Data Warehouse**, procedendo às necessárias transformações
 - Formato e conteúdo
 - Área de Tratamento de Dados (DSA)
 - Tem associado um conjunto de processos que permitem **extrair**, **transformar** e **carregar** os dados fonte para serem utilizados no *Data Warehouse*

Carregamento de Dados

- Sumário
 - Introdução
 - **Processo de Carregamento**
 - Técnicas SCD
 - Passos Típicos do Processo ETL

Processo de Carregamento



Processo de Carregamento

- Introdução
 - Depois de transformados, é necessário **carregar os dados** para a BD do *Data Warehouse*
 - Geralmente são carregados **muitos registos** de uma só vez
 - Técnicas de *bulk loading*
 - Ordem do carregamento
 - Tabelas de minidimensão
 - Tabelas de dimensão
 - Tabelas de factos

Processo de Carregamento

- Introdução
 - Criação de **chaves primárias** independentes das chaves utilizadas nos sistemas fonte
 - Criação de **registos especiais** para situações de exceção
 - Evitar a interrupção do carregamento
 - Construção de **agregados** de modo a acelerar as pesquisas
 - Depois de carregados, os dados são indexados

Processo de Carregamento

- Carregamento das Tabelas
 - É uma fase crítica em que eventuais **falhas** podem levar a **recuperações complexas**
 - Quase tudo o que é feito para **otimizar** o desempenho do *Data Warehouse* tende a **atrasar o carregamento**:
 - Índices
 - Agregados
 - Particionamento de tabelas, ...

Processo de Carregamento

- Carregamento Inicial
 - Disponibilização no *Data Warehouse* dos **dados extraídos** das fontes e **validados** na DSA
 - Geralmente o **primeiro carregamento** corre sempre bem
 - Importa **minimizar** ao máximo a janela de carregamento

Processo de Carregamento

- Carregamentos Periódicos
 - Para além do carregamento inicial é necessário resolver os **carregamentos periódicos**, com características diferentes
 - Atualizações de dimensões
 - Agregados, etc.
 - Questões a considerar:
 - Duração estimada do carregamento
 - Impacto na coerência do *Data Warehouse* caso o processo tenha de ser interrompido

Carregamento de Dados

- Sumário
 - Introdução
 - Processo de Carregamento
 - **Técnicas SCD**
 - Passos Típicos do Processo ETL

Técnicas SCD

- Introdução
 - Necessidade de preservar o **histórico** de dados num *Data Warehouse*
 - Os atributos das dimensões **podem mudar** ao longo do tempo
 - Necessária uma **estratégia** para lidar com as **alterações**
 - Técnicas SCD (*Slowly Changing Dimensions*)

Técnicas SCD

- Introdução
 - Técnicas para lidar com as alterações nas dimensões
 - Tipo 0 (SCD0)
 - Tipo 1 ([SCD1](#))
 - Tipo 2 ([SCD2](#))
 - Tipo 3 ([SCD3](#))
 - Tipo 4 (SCD4)
 - Tipo 6 (SCD6)

Técnicas SCD

- Alterações Tipo 1 (SCD1)
 - Consiste em **alterar** diretamente **o valor** de um ou mais campos
 - Sobreposição de valores
 - É útil, sobretudo quando se detetam **erros** nos dados
 - Nem sempre os **dados estão disponíveis** quando se cria um registo numa dimensão

Técnicas SCD

- Alterações Tipo 1 (SCD1)
 - Exemplo

SISTEMA FONTE

T_CLIENTES			
ID	Nome	Telemóvel	...
12345	João Lima	991234567	
54321	Maria Violeta	981234567	
...

DATA WAREHOUSE

T_DIM_CUSTOMER			
Key	Name	Mobile	...
1	João Lima	991234567	
2	Maria Violeta	981234567	
...

Técnicas SCD

- Alterações Tipo 1 (SCD1)
 - Exemplo

SISTEMA FONTE

T_CLIENTES			
ID	Nome	Telemóvel	...
12345	João Lima	991234567	
54321	Maria Violeta	987654321	
...

↑
número de
telemóvel mudou

DATA WAREHOUSE

T_DIM_CUSTOMER			
Key	Name	Mobile	...
1	João Lima	991234567	
2	Maria Violeta	987654321	
...

↑
atualizar o número
de telemóvel

Técnicas SCD

- Alterações Tipo 2 (SCD2)
 - Criação de **novo registo** na dimensão com a alteração pretendida
 - Necessária uma **coluna adicional** para indicar qual a **versão ativa** do registo
 - Permite **preservar** todo o **histórico** de dados

Técnicas SCD

- Alterações Tipo 2 (SCD2)
 - Exemplo

SISTEMA FONTE

T_CLIENTES			
ID	Nome	Telemóvel	...
12345	João Lima	991234567	
54321	Maria Violeta	981234567	
...

DATA WAREHOUSE

T_DIM_CUSTOMER			
Key	Name	Mobile	...
1	João Lima	991234567	
2	Maria Violeta	981234567	
...

Técnicas SCD

- Alterações Tipo 2 (SCD2)
 - Exemplo

SISTEMA FONTE

T_CLIENTES				
ID	Nome	Telemóvel	...	
12345	João Lima	991234567		
54321	Maria Violeta	987654321		
...	

↑
número de
telemóvel mudou

DATA WAREHOUSE

T_DIM_CUSTOMER				
Key	Name	Mobile	...	Active
1	João Lima	991234567		Yes
2	Maria Violeta	981234567		No
125	Maria Violeta	987654321		Yes
...

↑
novo registo para guardar a alteração
do número de telemóvel

Técnicas SCD

- Alterações Tipo 3 (SCD3)
 - Criação de um **campo adicional** que permitem registar a **alteração** do valor do atributo
 - Permite apenas guardar o **valor atual** e a **alteração anterior** ou o **valor inicial**
 - Não é preservado todo o **histórico** de dados

Técnicas SCD

- Alterações Tipo 3 (SCD3)
 - Exemplo

SISTEMA FONTE

T_CLIENTES			
ID	Nome	Telemóvel	...
12345	João Lima	991234567	
54321	Maria Violeta	981234567	
...

DATA WAREHOUSE

T_DIM_CUSTOMER			
Key	Name	Mobile	...
1	João Lima	991234567	
2	Maria Violeta	981234567	
...

Técnicas SCD

- Alterações Tipo 3 (SCD3)
 - Exemplo

SISTEMA FONTE

T_CLIENTES			
ID	Nome	Telemóvel	...
12345	João Lima	991234567	
54321	Maria Violeta	987654321	
...

↑
número de
telemóvel mudou

DATA WAREHOUSE

T_DIM_CUSTOMER				
Key	Name	Mobile	Moblie_Old	...
1	João Lima	991234567	Not Available	
2	Maria Violeta	987654321	981234567	
...

↑
novo atributo para guardar o número
antigo do telemóvel

Carregamento de Dados

- Sumário
 - Introdução
 - Processo de Carregamento
 - Técnicas SCD
 - Passos Típicos do Processo ETL

Processo ETL

- Passos Típicos
 - Planeamento
 - Carregamento de dimensões
 - Carregamento de factos
 - Automatizar o processo ao máximo
 - Infraestrutura para a área de tratamento de dados
 - Carregamento inicial e periódicos
 - Administração

Processo ETL

- Planeamento
 - Definir um **plano geral** (tipo *end-to-end*)
 - Mapa Lógico de Dados
 - Definir **infraestrutura** para a área de tratamento de dados
 - Escolher as **ferramentas** de **ETL**
 - Fazer **plano detalhado** analisando todos os problemas que é necessário resolver para carregar cada tabela destino
 - Fontes, transformações, etc.

Processo ETL

- Carregamento de Dimensões
 - Elaborar, testar e executar planos ETL para as **dimensões estáticas** e **simples**
 - Permite testar toda a infraestrutura
 - Elaborar, testar e executar planos ETL para as **dimensões que mudam**
 - Tratar todos os **restantes casos**
 - Dimensões geradas com dados manuais, dimensões especiais, etc.

Processo ETL


- Carregamento de Factos
 - Elaborar, testar e executar planos ETL para **tabelas de factos**
 - Elaborar e testar processo de **carregamentos periódicos**

Processo ETL

- Automatizar o Processo
 - Utilização de **ferramentas** sofisticadas de suporte
 - Escalonamento dos processos
 - Execução automática


Processo ETL

- Exemplo: Cadeia de Lojas



Processo ETL

• Exemplo: Cadeia de Lojas



Processo ETL

- Infraestrutura da DSA
 - Pode ir de uma **simples conta** no servidor do *Data Warehouse* a **máquinas dedicadas** de grande capacidade
 - A decisão depende do **volume de dados** e da **complexidade** das operações a fazer nos dados antes de os carregar
 - Tipicamente, para cada dimensão e tabela de factos, **prepara-se tudo** na área de tratamento de dados para depois fazer um **carregamento direto**

Processo ETL

- Carregamento Inicial
 - Feito **diretamente** da área de tratamento de dados para as tabelas do *Data Warehouse* (depois dos dados preparados)
 - Alguns **cuidados**:
 - Desligar sistemas de *logging*
 - Ordenar previamente os dados a carregar pela chave primária
 - Fazer, eventualmente, algumas **agregações** básicas durante o carregamento


Processo ETL

- Carregamentos Periódicos
 - Definir **estratégia** para identificar novos dados nos sistemas fonte
 - Novas transações
 - Atualizações a dados de transações anteriores
 - Identificar:
 - Registros novos para cada dimensão
 - Atualizações de atributos de dimensões e como estas vão ser tratadas
 - Novos factos ou medidas numéricas

Processo ETL

- Administração
 - **Construir, utilizar e manter** as ferramentas de extração de dados
 - **Garantir** a qualidade dos dados, após cada extração
 - **Construir e manter** agregados
 - **Vigiar e afinar** o desempenho do sistema
 - Fazer **cópias de segurança** e **recuperar** o estado da BD do *Data Warehouse* em caso de falha

Processo ETL



Carregamento de Dados

- Referências
 - The Data Warehouse ETL Toolkit, R. Kimball e J. Caserta, John Wiley & Sons, 2004
 - Capítulos 1, 2, 5 e 6
 - Sistemas de Suporte à Decisão, B. Cortes, FCA, 2005
 - Capítulo 3